

Final Assignment Kapita Selekt SC:
Analisis Saturasi & Halusinasi pada RAG

Team:

Teuku Aldi Fadhlur Rahman (22/496088/PA/21298)
Muhammad Haiqal Dwikusuma (22/496221/PA/21330)

Link Github:

<https://github.com/taibaik/rag-saturasi-halusinasi-kssc>

PENDAHULUAN

Retrieval-Augmented Generation (RAG) merupakan pendekatan yang menggabungkan kemampuan *retriever* untuk mengambil informasi relevan dari basis pengetahuan eksternal dengan kemampuan *generator* (LLM) untuk menyusun jawaban berdasarkan informasi tersebut. Pendekatan ini banyak digunakan untuk mengatasi keterbatasan pengetahuan statis pada LLM, terutama untuk domain atau bahasa dengan data pelatihan yang terbatas, seperti Bahasa Indonesia.

Namun, beberapa penelitian menunjukkan bahwa performa RAG tidak selalu meningkat secara linear seiring bertambahnya jumlah dokumen konteks yang diambil (*Top-K retrieval*). Pada nilai K tertentu, performa cenderung **mengalami saturasi** atau bahkan menurun, dan LLM semakin rentan menghasilkan **halusinasi**, khususnya dalam bentuk sitasi yang tidak akurat — jawaban tampak meyakinkan namun merujuk pada dokumen yang salah.

Laporan ini menyajikan hasil eksperimen sistem RAG yang dibangun menggunakan dataset **IDK-MRC**, dengan **FAISS** sebagai vector store, **sentence-transformers** sebagai embedding model, dan **Qwen2.5-1.5B-Instruct** (4-bit) sebagai generator. Eksperimen dilakukan dengan memvariasikan nilai $K = 1, 3, 5$, dan 10 , untuk menganalisis (1) bagaimana kualitas jawaban berubah terhadap K , dan (2) bagaimana akurasi sitasi LLM dipengaruhi oleh jumlah dokumen dalam konteks.

METODE

2.1 Arsitektur RAG

Sistem yang dibangun mengikuti arsitektur **Retrieval-Augmented Generation (RAG)** standar, terdiri dari tiga komponen utama: *retriever*, *vector store*, dan *generator (LLM)*. Alur kerjanya adalah sebagai berikut: (1) pertanyaan pengguna diubah menjadi vektor embedding, (2) vektor ini digunakan untuk mencari *top-K* dokumen paling relevan dari vector store menggunakan *cosine similarity*, (3) dokumen-dokumen yang ditemukan disusun ke dalam prompt bersama pertanyaan, dan (4) LLM menghasilkan jawaban berdasarkan konteks yang diberikan.

2.2 Dataset

Digunakan dataset **IDK-MRC** (*I Don't Know — Machine Reading Comprehension*) dari HuggingFace, yang berisi pasangan pertanyaan-jawaban berbahasa Indonesia beserta passage konteksnya, termasuk pertanyaan yang *unanswerable* (tidak memiliki jawaban dalam konteks). *Split validation* (358 baris) digunakan sebagai korpus dan sumber evaluasi. Setiap baris di-*flatten* sehingga satu pasangan pertanyaan-jawaban menjadi satu entri evaluasi, menghasilkan korpus dokumen unik untuk vector store. Karena keterbatasan waktu komputasi pada Google Colab Free, eksperimen dibatasi pada **100 sampel acak** (seed=42) dari hasil flattening tersebut.

2.3 Retriever & Vector Store

Embedding dihasilkan menggunakan model **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2**, sebuah model ringan yang mendukung Bahasa Indonesia. Seluruh passage dalam korpus di-encode menjadi vektor, dinormalisasi (L2-normalize), kemudian diindeks ke dalam **FAISS IndexFlatIP** sehingga *inner product* antar vektor yang ternormalisasi setara dengan *cosine similarity*. Pada saat retrieval, query di-encode dan dinormalisasi dengan cara yang sama, lalu dicari **top-K** dokumen dengan skor similarity tertinggi, untuk K = 1, 3, 5, dan 10.

2.4 Generator (LLM)

Model generator yang digunakan adalah **Qwen/Qwen2.5-1.5B-Instruct**, dimuat dengan **kuantisasi 4-bit** (bitsandbytes, tipe kuantisasi nf4, *double quantization*, compute_dtype=float16) agar dapat dijalankan pada GPU T4 (Google Colab Free). Generasi jawaban menggunakan **greedy decoding** (do_sample=False) untuk memastikan hasil yang reproducible, dengan batas maksimum 200 token baru per jawaban.

2.5 Desain Prompt

Prompt dirancang untuk secara eksplisit menginstruksikan LLM agar:

- 1 Menjawab **hanya berdasarkan konteks** yang diberikan,
- 2 Menjawab dalam **Bahasa Indonesia** secara singkat,
- 3 **Menyertakan nomor sitasi** [1], [2], dst. yang merujuk ke nomor urut dokumen pada konteks yang digunakan sebagai dasar jawaban,
- 4 Menjawab **“Tidak tahu”** apabila jawaban tidak terdapat dalam konteks yang diberikan (mengakomodasi pertanyaan *unanswerable* pada IDK-MRC).

Setiap dokumen hasil retrieval diberi label [1] sampai [K] sesuai urutan *rank* sebelum disusun ke dalam blok konteks pada prompt.

2.6 Metrik Evaluasi

Untuk setiap nilai K, dua aspek diukur pada 100 sampel evaluasi:

(a) **Kualitas Jawaban** — dibandingkan terhadap jawaban *ground truth* menggunakan:

- **ROUGE-1, ROUGE-2, ROUGE-L** (text overlap, F1-score, tanpa stemming),
- **BLEU** (dengan *smoothing function* method1 dari NLTK),

- **BERTScore F1** (semantic similarity, model bert-base-multilingual-cased, lang='id').

(b) **Akurasi Sitasi** — dihitung dengan mengekstrak nomor sitasi [n] dari jawaban LLM menggunakan regex, kemudian memeriksa apakah salah satu dokumen yang disitasi adalah dokumen yang memang mengandung jawaban (gold_context). Skor bernilai 1.0 jika minimal satu sitasi mengarah ke dokumen yang benar, dan 0.0 jika tidak.

HASIL EKSPERIMEN

3.1 Tabel Performa per Nilai K

Tabel berikut menunjukkan rata-rata skor metrik kualitas jawaban dan akurasi sitasi pada 100 sampel evaluasi untuk setiap nilai K:

K	ROUGE-1	ROUGE-2	ROUGE-L	BLEU	BERTScore F1	Citation Accuracy
1	0.0885	0.0541	0.0872	0.0213	0.3117	0.67
3	0.0874	0.0565	0.0867	0.0190	0.3105	0.70
5	0.0873	0.0542	0.0863	0.0168	0.3111	0.76
10	0.0752	0.0452	0.0739	0.0167	0.2968	0.36

3.2 Grafik Performa vs K

Show Image

Grafik 1 (Kualitas Jawaban vs K) menampilkan tren ROUGE-1, ROUGE-2, ROUGE-L, BLEU, dan BERTScore F1 terhadap nilai K. Secara umum, kelima metrik menunjukkan **performa yang relatif stabil pada K = 1, 3, dan 5** (perbedaan antar metrik sangat kecil, dengan selisih ROUGE-L hanya sekitar 0.001–0.001 antar K), namun **mengalami penurunan tajam pada K = 10** di seluruh metrik kualitas jawaban.

Grafik 2 (Citation Accuracy vs K) menunjukkan tren yang berbeda: akurasi sitasi justru **meningkat dari K=1 (67%) ke K=5 (76%)**, sebelum **menurun drastis ke K=10 (36%)** — penurunan lebih dari setengah dibandingkan K=5.

3.3 Analisis Kualitatif — Contoh Kasus

Untuk mengilustrasikan perilaku model, berikut adalah perbandingan output pada satu sampel yang sama (pertanyaan: “berapakah luas Jember?”, jawaban asli: “3.293,34 Km²”) di setiap nilai K:

K	Prediksi	ROUG E-L	BERTSc ore F1	Citation Acc
1	"Luas Jember adalah 3.293,34 km ² . [1]"	0.2857	0.6307	1
3	"3.293,34 km ² [1]."	0.5455	0.6916	1
5	"3.293,34 km ² [1]"	0.6667	0.7653	1
10	"...kaan Indonesia.\n\n[10] Sejarah Budaya Indonesia, atau sejarah budaya Indonesia, adalah sejarah dan seni budayanya yang dilakukan oleh bangsa Indonesia..." (output tidak relevan, berulang)	0.0000	0.4271	0

Pada contoh ini, kualitas jawaban justru **meningkat** dari K=1 ke K=5 (ROUGE-L naik dari 0.2857 ke 0.6667) karena jawaban menjadi semakin ringkas dan tepat sasaran. Namun pada K=10, model **gagal total** — alih-alih menjawab pertanyaan, model menghasilkan teks yang tidak relevan dan berulang (*repetitive generation*), menyitasi dokumen [10] yang membahas topik yang sama sekali berbeda ("Sejarah Budaya Indonesia").

3.4 Ringkasan Temuan

- 1 **Saturasi performa** terjadi pada K=10: seluruh metrik kualitas jawaban (ROUGE-1/2/L, BLEU, BERTScore) menurun dibandingkan K=1, 3, dan 5 yang relatif setara.
- 2 **Citation accuracy memiliki pola non-monoton**: meningkat hingga K=5, lalu turun tajam pada K=10.
- 3 **K=10 menunjukkan tanda-tanda context overload**: jawaban menjadi tidak relevan, repetitif, dan menyitasi dokumen yang salah — mengindikasikan model kehilangan fokus terhadap pertanyaan asli ketika konteks terlalu panjang.

ANALISIS & DISKUSI

4.1 Saturasi Performa Kualitas Jawaban

Hasil eksperimen menunjukkan bahwa performa kualitas jawaban relatif stabil pada K = 1, 3, dan 5, dengan perbedaan antar nilai K yang sangat kecil (selisih ROUGE-L maksimal 0.001). Namun terjadi penurunan tajam dan signifikan pada K = 10 di seluruh metrik — ROUGE-1 turun dari 0.0885 menjadi 0.0752, ROUGE-L dari 0.0872 menjadi 0.0739, dan BERTScore F1 dari 0.3117 menjadi 0.2968.

Fenomena ini dapat dijelaskan melalui dua mekanisme yang saling memperkuat. Pertama, ketika K membesar, dokumen yang diambil oleh retriever semakin tidak relevan terhadap pertanyaan. Pada

K=1, hanya dokumen paling mirip secara semantik yang masuk ke konteks. Pada K=10, dokumen ke-6 hingga ke-10 memiliki skor cosine similarity yang jauh lebih rendah dan berpotensi membahas topik yang tidak berkaitan sama sekali dengan pertanyaan. Hal ini memperkenalkan *noise* ke dalam konteks yang harus diproses oleh LLM.

Kedua, model Qwen2.5-1.5B-Instruct yang digunakan merupakan model berukuran kecil (1.5 miliar parameter) dengan kemampuan atensi yang terbatas. Ketika panjang konteks meningkat akibat banyaknya dokumen yang dimasukkan ke prompt, model mengalami apa yang dikenal sebagai efek *lost-in-the-middle*: informasi yang relevan namun berada di tengah konteks panjang cenderung diabaikan oleh mekanisme atensi model. Akibatnya, alih-alih berfokus pada dokumen yang paling relevan, model justru terpengaruh oleh dokumen-dokumen *noise* yang ada di akhir konteks, menghasilkan jawaban yang tidak akurat atau bahkan tidak relevan sama sekali.

Contoh kasus pada pertanyaan "berapakah luas Jember?" mengilustrasikan ini dengan jelas: pada K=10, model menghasilkan teks berulang tentang "Sejarah Budaya Indonesia" yang sama sekali tidak berhubungan dengan pertanyaan, dengan ROUGE-L = 0.0000. Ini adalah manifestasi ekstrem dari *context overload* pada model kecil.

4.2 Perilaku Non-Monoton Akurasi Sitasi

Berbeda dengan metrik kualitas jawaban, akurasi sitasi menunjukkan pola non-monoton yang menarik: meningkat dari 67% pada K=1 ke 76% pada K=5, sebelum turun drastis ke 36% pada K=10. Pola ini mencerminkan dua efek yang berlawanan arah seiring meningkatnya K.

Peningkatan akurasi sitasi dari K=1 ke K=5 dapat dijelaskan oleh peningkatan probabilitas *recall*: semakin banyak dokumen yang diambil, semakin besar kemungkinan dokumen yang mengandung jawaban benar (*gold context*) termasuk dalam konteks yang diberikan ke LLM. Pada K=1, jika retriever gagal menempatkan *gold context* sebagai dokumen pertama, tidak ada kesempatan lain — akurasi sitasi langsung nol untuk sampel tersebut. Pada K=5, model memiliki lebih banyak “kesempatan” untuk menyitasi dokumen yang tepat.

Namun pada K=10, efek negatif dari *context overload* mendominasi. Meskipun *gold context* kemungkinan besar ada dalam daftar 10 dokumen yang diambil, model justru semakin kesulitan mengidentifikasi dokumen mana yang paling relevan. Dengan 10 dokumen bernomor [1] hingga [10] di dalam prompt, model kecil ini kehilangan kemampuan *tracking* yang presisi — ia menyebut nomor sitasi secara sembarangan atau mengikuti pola dokumen terakhir (seperti [10] pada contoh kasus), bukan berdasarkan relevansi konten.

Penurunan akurasi sitasi sebesar 40 poin persentase dari K=5 ke K=10 (dari 76% ke 36%) mengindikasikan bahwa halusinasi sitasi pada model ini bukan semata-mata disebabkan oleh ketidaktahuan model terhadap jawaban, melainkan oleh ketidakmampuan model untuk melacak asal informasi dalam konteks yang panjang dan kompleks.

4.3 Implikasi Praktis dan Rekomendasi

Berdasarkan hasil dan analisis di atas, beberapa implikasi praktis dapat ditarik untuk pengembangan sistem RAG berbahasa Indonesia:

- Nilai K optimal untuk sistem ini berada di rentang $K=3$ hingga $K=5$. Pada rentang ini, sistem mencapai keseimbangan terbaik antara kualitas jawaban dan akurasi sitasi, tanpa risiko *context overload*.
- Penggunaan model generator yang lebih besar (misalnya Qwen2.5-7B atau lebih besar) kemungkinan akan menggeser titik saturasi ke nilai K yang lebih tinggi, karena model yang lebih besar memiliki kapasitas atensi yang lebih baik untuk memproses konteks panjang.
- Strategi *re-ranking* dokumen sebelum dimasukkan ke prompt dapat membantu memastikan dokumen yang paling relevan selalu berada di posisi awal konteks, sehingga mengurangi dampak *lost-in-the-middle*.
- Instruksi sitasi dalam prompt terbukti cukup efektif pada K rendah ($K=1$ hingga $K=5$), namun perlu diperkuat atau dimodifikasi untuk K tinggi — misalnya dengan mempersingkat representasi setiap dokumen atau menggunakan teknik *chain-of-thought* untuk mendorong model melacak sumber secara eksplisit.

4.4 Keterbatasan Eksperimen

Beberapa keterbatasan perlu dicatat dalam menginterpretasikan hasil ini. Eksperimen dilakukan hanya pada 100 sampel acak dari split validation IDK-MRC akibat keterbatasan waktu komputasi pada Google Colab Free, sehingga hasil mungkin tidak sepenuhnya representatif terhadap keseluruhan distribusi dataset. Selain itu, metrik evaluasi yang digunakan (ROUGE, BLEU, BERTScore) mengukur kemiripan tekstual dengan *ground truth*, namun tidak selalu mencerminkan kualitas jawaban secara semantik — jawaban yang benar namun diformulasikan berbeda dari *ground truth* dapat mendapat skor rendah. Terakhir, penggunaan *greedy decoding* memastikan *reproducibility* namun membatasi variabilitas output yang mungkin lebih merepresentasikan kemampuan model yang sesungguhnya.

PEMBAGIAN KERJA

Teuku Aldi Fadhlur Rahman — RAG Pipeline & Retrieval

Tanggung jawab utama: Membangun fondasi sistem.

- Memuat dan melakukan prapemrosesan dataset IDK-MRC dari HuggingFace
- Menyiapkan model embedding (sentence-transformers)
- Membangun penyimpanan vektor (FAISS atau ChromaDB) dan logika pengindeksan
- Menerapkan logika pencarian Top-K untuk $K = 1, 3, 5, 10$
- Merancang dan menguji templat prompt (termasuk instruksi kutipan ke LLM)

Muhammad Haiqal Dwikusuma — Generasi, Evaluasi & Pelaporan

Tanggung jawab utama: Generasi LLM + mengukur semuanya.

- Memuat dan mengonfigurasi LLM generator (Qwen/Gemma dengan kuantisasi 4-bit)
- Menghubungkan output retriever Orang A ke dalam pipa RAG lengkap
- Menerapkan evaluasi ROUGE, BLEU, dan BERTScore terhadap ground truth
- Menerapkan logika pengukuran akurasi kutipan
- Membuat tabel dan grafik hasil
- Menulis laporan ringkasan PDF